Classificação de tópicos: relatório do case Vício (Método VDE)

17/10/2026 · Código, dados e decisões: README · Decisões tomadas à mão: `decisoes_manuais.md`

Resultado.

- Das 359 questões: **81 publicadas (23%)**, 276 para revisão (todas com tema sugerido) e 2 fora. Precisão prevista nas publicadas: **0,97** (intervalo de 0,93 a 1,00).
- Custo: 1.903 chamadas a modelos (~10,6 h de chamadas somadas); US$ 0 pagos, porque usei assinaturas que já tinha; 3 h de rotulagem manual.

a) Como pensei

A régua decide o desenho. A meta é "95% de acerto nas publicadas, publicando o máximo". Com ela, o problema deixa de ser só acertar o tema: é **saber quando se acertou**. Por isso decidi como medir antes de escolher modelo. Parti de quatro hipóteses:

1. **Irmão é o erro mais caro.** O erro que mais pesa não é entender mal a questão: é escolher o **subtema irmão** errado. A régua aceita pai e filho, mas não irmão.
2. **Parte do erro é convenção da árvore**, não de Direito: em temas duplicados ou sobrepostos, o conteúdo pode estar certo e o nó, errado.
3. **Concordância separa o certo do duvidoso.** A concordância entre fontes independentes faz isso melhor que a confiança declarada por um modelo.
4. **O assunto de origem** das questões não serve como rótulo.

Dados antes de modelo. A análise exploratória (`saidas/eda/`) mudou o plano antes da primeira chamada.

- Só 20 dos 373 temas abaixo das disciplinas têm descrição de verdade. O resto tem só um texto-modelo ("Subtema de X. N questões") ou nada.
- Há 20 nós "fantasmas": cópias sem descrição e sem histórico.
- O assunto de origem bate com dois temas válidos em 67 questões. Nas 58 que também citam uma lei especial, ele cai no mesmo ramo da lei 0 vezes.

O que mudou: o assunto de origem nunca entra no prompt; escrevi, com um LLM, **cartões** para os 351 temas utilizáveis (definição, o que entra, o que não entra e para onde vai); e registrei à mão a convenção dos duplicados (D1) e as regras de desempate das sobreposições (D2).

Um gabarito antes de tudo. Rotulei à mão 60 questões sorteadas (estratificadas, semente fixa), **sem ver resposta de modelo**, em 3 horas. Elas medem o acerto, calibram a confiança e escolhem o limiar. O rótulo nunca decide uma questão. Toda medida usa probabilidade fora da amostra (validação cruzada).

O pipeline: quatro fontes e um verificador.

- **Classificadores A e B**, de famílias diferentes. A (GPT) vê a árvore inteira, com o escopo de cada tema; B (Gemini) é hierárquico: escolhe o tema e depois o subtema, com os cartões.
- **Voto barato** (GPT-OSS, modelo aberto, árvore enxuta) e **regras** pelas leis citadas.
- **Verificador contrastivo:** recebe os cartões do candidato, do pai, dos irmãos e do par de outra disciplina, sem saber qual é o candidato, e escolhe um deles. Ataca a hipótese 1.
- **Recuo para o pai:** quando a dúvida é entre irmãos, a questão vai para o pai, que a régua aceita. Nunca recua até a disciplina.

O que testei.

- **Régua estrita:** vale o tema que rotulei, o pai ou um filho dele.
- **Cobertura a 95%:** a fração do gold que daria para publicar com 95% de acerto, ordenando pela confiança.

Experimento	Resultado no gold (60)	Decisão
E0: assunto de origem como rótulo	12 de 33 (36%)	Hipótese 4 confirmada: o assunto fica só como sinal fraco
E2: um LLM sozinho (A)	52 de 60 (87%); cobertura a 95%: 67%	"Razoável, não publicável". A autoconfiança não é calibrada: A declara 0,99 em erros
E3: B erra diferente de A?	B 52 de 60; os dois erram juntos 4 vezes, contra ~1 se fossem independentes	Parcialmente derrubada: a concordância de A e B não basta
E3b: voto barato	30 de 60 (50%)	Fraco sozinho, bom detector de dúvida

Experimento	Resultado no gold (60)	Decisão
E4: cartões × só títulos (em B)	52 × 53 acertos; cobertura a 95%: 78% × 62%	Derrubada no acerto. Cartões mantidos: separam o certo do duvidoso
E5: pipeline × A sozinho	Mesma precisão em cada cobertura (top 28: 28/28 × 27/28)	"O ensemble acerta mais": derrubada. "Sabe quando acertou": confirmada

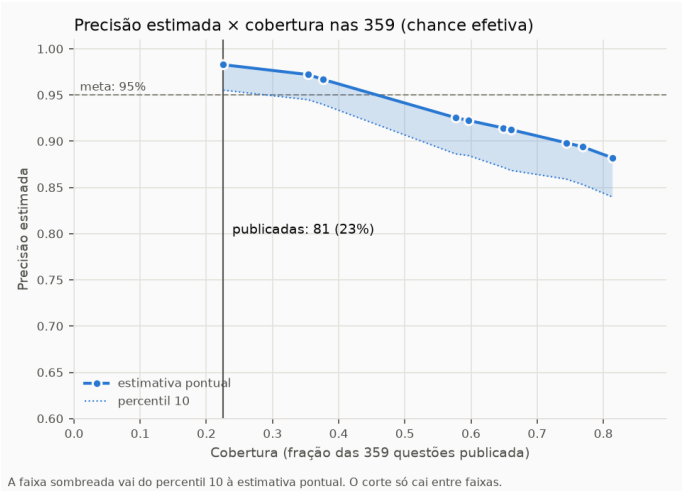
O E5 virou a regra de publicação. Quando o verificador confirma e A, B e o voto barato caem no mesmo ramo (**consenso total**), o gold tem 28 acertos em 28. Na faixa seguinte (o verificador confirma, mas alguma fonte discorda), 19 em 22. Publicar exige a primeira faixa.

Becos sem saída.

- **Regressão logística** com 7 sinais para calibrar: com 6 erros em 60, empatou com um palpite constante. Troquei por taxas de acerto por faixa de sinais, com suavização de Jeffreys, que venceram na validação cruzada (log-loss 0,29 × 0,31).
- **A primeira prévia publicou zero.** A regressão comprimia tudo em ~0,92, e eu descontava a ambiguidade do rótulo no lugar errado.
- **Modelos.** Comecei com Claude por API. A máquina não tinha chave paga, e repetir o mesmo modelo não dá opiniões independentes. Criei uma camada de provedores plugáveis e escolhi um modelo por papel. Descartados: o modelo local (4B), que gerava 2 tokens/s; o Gemini "high", que levaria 27 h; e um modelo do Hugging Face treinado em projetos de lei, que não classifica.
- **Cotas das assinaturas.** Foram o gargalo real. A CLI do Claude esgotou no meio dos cartões, e o verificador trocou de Claude para Gemini. Isso o deixou na mesma família de B, um risco que aceitei.
- **Embeddings:** adiados, porque a árvore inteira cabe no prompt.

Do limiar à previsão.

- **Chance de acerto de cada candidata:** a taxa da sua faixa, multiplicada por (1 − taxa suposta de discordância de convenção do nó). As taxas supostas são 20% para cópia em outra disciplina, 10% para sobreposição e 3% para "(Parte N)".
- **Limiar:** publico o maior conjunto cujo **percentil 10** da precisão fica em 95% ou mais (1.000 sorteios da incerteza das faixas).
- **Resultado:** as 81 questões de consenso total em temas sem risco de convenção.
- **Ponto previsto:** a média de dois estimadores. Um é a taxa da faixa (0,983). O outro é o acerto do gold que caiu nas publicadas: 13 de 13, suavizado para 0,964, para não tratar 13 acertos como certeza (D12). A média dá **0,97**. O intervalo vem dos sorteios.
- **O que não medi:** a precisão numa amostra independente (a mesma amostra calibra e confere), a convenção real dos especialistas e a variação dos modelos entre execuções.



A faixa seguinte (consenso em temas "(Parte N)") levaria a cobertura a 35%, com ponto de 0,97. Mas o percentil 10 cai para ~0,945, abaixo da régua. Só a confirmação da convenção resolve isso (memo).

b) Diagnóstico

Nas questões.

- **Ruído do banco:** "\n" e "\t" gravados como texto em 106 questões (29%); uma questão com 108 mil caracteres de HTML colado do Word. O campo "comando" quase nunca ajuda: vazio em 101 questões, gerado por outra

ferramenta em 62, cópia do enunciado em 72, frase-padrão em 74. Só 50 trazem informação.
- **Enunciados genéricos** ("Assinale a correta") com alternativas de temas diferentes: no gold, 20% são multitema. Não há um tema central único, e qualquer escolha pode errar.
- **Certo/errado (58):** as alternativas não dizem nada; às vezes a afirmação está no comando.
- **Jurisprudência (49):** o tema vem do caso julgado, não de um artigo de lei.
- **Rótulos de origem errados.** Exemplos: extorsão mediante sequestro como "Lesão Corporal"; falso testemunho como "Concurso de Crimes". Quem confia neles herda os erros (36%).

Nos temas.

- **Sem definição:** o título é a única pista, para máquina e para humano. "Conceitos e Espécies de Prisão", "Prisão Preventiva" e "Medidas Cautelares Diversas" só se separam com uma regra escrita.
- **Duplicados:** 20 fantasmas (ativos, sem descrição e sem questões).
  - Exemplos: "Penal > Lei Maria da Penha" ao lado de "Legislação Especial > Lei Maria da Penha"; "Teoria da Pena (Parte 1)" e "(Parte 2)".
  - A equipe disse que a escolha fica a critério do candidato. Adotei o nó com histórico (D1), mas o gabarito pode ter usado o outro.
- **Sobreposições:** "Ação Penal" em Penal e em Processo Penal; Juizados; interceptação; "Teoria da Pena" × "Teorias Legitimadoras da Pena".
- **Lixeiras:** "Conceito e Fontes do Direito Penal" concentra 74% das questões do tema; "Lei Penal no Tempo", 80%. Na dúvida, modelo e humano escapam para o tema introdutório.
- **Títulos com erro:** "Crimonológicas", "Comeptência", "Estaturo".

Que questão é difícil, com evidência.

- **Irmãos e fronteiras.** O pipeline errou o tema sugerido em 6 questões do gold, e as 6 foram para revisão. Em 5 delas, o tema escolhido estava na minha própria lista de "também plausível".
  - Três erros são entre irmãos: dois entre "Teorias de Nível Sociológico" e "Teorias Criminológicas em Espécie", que se sobrepõem; um em ação penal privada.
  - Três são fronteiras entre temas: prazos do inquérito × denúncia; atribuição da Polícia Federal × competência; correspondência do preso (LEP × inviolabilidade).
- **Convenção.** É ela que derruba a cobertura de Legislação Especial: só 12% publicadas, contra 40% em Criminologia, 26% em Penal e 19% em Processo Penal. LEP (15 questões), Drogas (11) e Maria da Penha (9) vão para revisão porque o tema tem cópia em outra disciplina.
- **De onde vêm as 276 revisões:**
  - 46 têm consenso total, mas em temas "(Parte N)";
  - 51 estão em temas com cópia em outra disciplina (30 delas com consenso total);
  - 28 estão em sobreposições;
  - o resto é discordância entre as fontes (na faixa "confirma parcial", 86% de acerto no gold), dúvida do verificador, multitema e 14 "possível fora do recorte".

c) Produção: 50 mil questões por semana

O case deixou três lições:

1. A qualidade não depende de um LLM mais forte: depende de **evidência** para saber quando se acertou.
2. Assinaturas não escalam: cotas que acabam em horas, nenhum processamento em lote e 13 a 66 mil tokens de sobrecarga do agente por chamada.
3. O custo dominante é o tempo do professor.

Arquitetura: cascata de custo crescente, com humano no ciclo.

```
importação → texto canônico → duplicatas (hash, embeddings): duplicata validada herda o tema
  → cache por (questão, versão da árvore, versão do pipeline): só segue o novo, mudado ou
reportado
  → N1: classificador treinado + voto barato; se concordam com P alta, decide
  → N2 (o resto): dois LLMs de famílias diferentes + verificador, em lote, árvore em cache
  → limiar por disciplina → publicar | fila do professor (acessos × incerteza) | fora
```

Tipo de IA	Onde entra	Por quê
Embeddings (modelo próprio)	Toda questão: duplicatas, vizinhos já validados, agrupar os "fora"	Quase de graça; reaproveita os rótulos

Tipo de IA	Onde entra	Por quê
Classificador treinado	N1	Custo ~zero; melhora toda semana com as revisões
LLM pequeno ou aberto	Voto barato em toda questão nova	Detecta dúvida a baixo custo (E3b)
LLMs fortes + verificador	N2, só nos incertos	A qualidade compensa ali; famílias diferentes mantêm a independência dos votos
Agentes	Fora do fluxo por questão: manutenção da árvore (propor temas a partir dos "fora", sugerir fusões)	A árvore cabe no contexto; agente por questão encarece e dificulta auditar
Professor	Fila priorizada com sugestão, segunda opção e definições	Fonte da verdade; cada decisão vira rótulo

Custo por questão.

Base: o perfil de tokens medido no case, sem a sobrecarga das CLIs. No N2, são ~70 mil tokens de entrada por questão, ~85% deles repetidos (árvore e cartões) e em cache de prompt. A saída tem 5 a 12 mil tokens, quase tudo raciocínio do verificador. O preço é o de lista de um modelo intermediário, em lote.

Etapa	Custo
N1: embeddings, classificador e voto barato em lote	~US$ 0,002 por questão
N2	~US$ 0,04 a 0,08 por questão que chega até ele
N2 na média, com 35% a 50% das questões chegando lá	~US$ 0,015 a 0,04 por questão
Total de máquina	**~US$ 0,02 a 0,04 por questão processada**

- **Rodada completa:** as 50 mil saem por US$ 1 a 2 mil.
- **Semana típica:** com o cache, só o que mudou é processado. Exemplo: 5 mil questões, US$ 100 a 200.
- **Comparação:** o ensemble completo em todas as 50 mil, toda semana, custaria US$ 4 a 7,5 mil.
- **Professor:** rotular do zero me custou 3 min por questão; validar uma sugestão deve levar ~1 min. Por isso a fila é ordenada por impacto (acessos dos alunos) e não precisa zerar: o que não foi revisado não é publicado.

Qualidade contínua.

- **Auditoria semanal:** 150 publicadas sorteadas por disciplina, revisadas por professores. A precisão sai com intervalo; se o limite inferior cair abaixo de 95%, o limiar sobe sozinho.
- **Gold de regressão** (~500 rótulos): nenhuma troca de prompt, modelo, cartão ou árvore entra sem passar nele.
- **Reportes de alunos:** a questão reportada volta para a fila com prioridade. Um painel mostra a taxa de reporte por tema, por versão e por modelo; um pico aponta lixeira, definição ruim ou piora de um modelo.
- **Deriva por lote de importação:** distribuição de temas e taxas de publicar, revisar e fora.
- **Versionamento:** cada decisão grava modelo, prompt e as versões da árvore, dos cartões e da calibração. O cache do case já faz isso por chamada.

Encaixe nos fluxos.

- **Importação:** lote noturno.
- **Revisão:** uma tela com a questão, a sugestão, a segunda opção e as definições. Aceitar leva um clique, e cada aceite realimenta o N1 e a calibração.
- **Reportes:** viram sinal de qualidade e prioridade na fila.
- **Mudança na árvore:** reclassifica só as questões cujos candidatos tocam os nós alterados.

Já servem à produção: o texto canônico, a camada de provedores com cache e custo, os cartões e a calibração.

O que faria com mais tempo

1. **Confirmar a convenção com a equipe e reprocessar**, sem nenhuma chamada nova. A cobertura iria de 23% para 35% só com os "(Parte N)", e para 46% com todos os duplicados.
2. **Revisar os cartões das zonas de risco** com um especialista. Ficaram como rascunho do modelo (D7).
3. **Ampliar o gold** em 150 questões, concentradas na faixa "confirma parcial" e nos temas de risco. Isso certificaria mais faixas e testaria a previsão numa amostra independente.
4. **Rodar o E6:** comparar modelos por papel e trocar o verificador para uma família diferente da de B.
5. Medir a variação entre execuções (rodar duas vezes) e usar embeddings para achar duplicatas.

d) Memo para o professor

Assunto: classificação automática das 359 questões: o que encontrei e do que preciso de você.

O que foi feito. Um sistema leu as 359 questões e sugeriu um tema para cada uma. Ele só publica sozinho quando várias "opiniões" independentes concordam e um conferente confirma. Conferi à mão uma amostra desse grupo e não encontrei erro. O resto vai para você, sempre com uma sugestão.

Resultado.

- **81 publicadas (23%).** Estimo 97% de acerto (entre 93% e 100%).
- **276 na sua fila**, cada uma com o tema sugerido, as alternativas e o motivo da dúvida.
- **2 fora do recorte:**
  - Q0142: isenção de ITCD, Direito Tributário;
  - Q0168: suborno de técnico de futebol para alterar o resultado de um jogo; nenhum tema da árvore cobre esse crime.

O que encontrei nos temas. É o que mais atrapalha, para a máquina e para quem estuda.

1. **Quase nenhum tema tem definição:** só 20 de 373 têm descrição de verdade. O título é a única pista.
2. **Temas duplicados.** "Lei Maria da Penha", "Tráfico de Drogas", "Lavagem" e "Lei de Execução Penal", entre outros, existem em Legislação Especial e também em Penal ou em Processo Penal. "Teoria da Pena (Parte 1)" e "(Parte 2)" convivem com "Teoria da Pena". As cópias não têm nenhuma questão.
3. **Temas que viraram "lixeira":** "Conceito e Fontes do Direito Penal" reúne 74% das questões do tema; "Lei Penal no Tempo", 80%.
4. **Temas sobrepostos:** "Ação Penal" em Penal e em Processo Penal; Juizados Especiais; "Teoria da Pena" × "Teorias Legitimadoras da Pena".
5. **Subtemas que se confundem:** "Teorias de Nível Sociológico" × "Teorias Criminológicas em Espécie" respondem por 2 dos 6 erros que encontrei na minha amostra.
6. **Títulos com erro de digitação:** "Crimonológicas", "Comeptência", "Estaturo".

O que recomendo mudar.

- **Apagar as cópias e os "(Parte N)"**, movendo o que houver para o tema original.
- **Escrever uma linha por tema:** "entra / não entra / vai para". Deixei um rascunho para os 351 temas; falta a sua validação.
- **Dividir as lixeiras** em subtemas concretos.
- **Escrever a regra dos pares material × processual.** Exemplo: CP, arts. 100 a 106, em Penal; denúncia e queixa em Processo Penal.
- **Corrigir os títulos.**

Do que preciso de você, por ordem de impacto.

1. **Uma regra sobre os duplicados (~30 min).**
   - A pergunta: numa questão de LEP, o tema certo é "Legislação Especial > LEP" ou "Processo Penal > LEP"? E nos "(Parte N)", vale o tema sem número?
   - Usei o tema que tem histórico de questões. Se você confirmar só a regra dos "(Parte N)", publico mais **46 questões**, sem refazer nada: a cobertura vai de 23% para 35%. Confirmando também as cópias, **84 questões** (46%).
2. **Validar as definições dos temas de risco** (~2 h): as cópias, as 6 sobreposições e as 11 lixeiras mais fortes.
3. **Revisar a fila de 276 questões**, a 1 ou 2 min cada (a sugestão já vem pronta). A coluna de confiança mostra por onde começar: nas 46 de consenso, deve bastar confirmar.
4. **Confirmar os 2 "fora"** e olhar 14 questões que talvez sejam de outra matéria.
5. **Daqui para a frente:** revisar uma amostra de ~150 publicadas por semana, para saber se os 95% se mantêm.